Завдання: На основі будь-якого access.log сформувати датасет, що надав би інформацію про користувачів веб-ресурсу

Виконати наступні кроки:

Функції для парсингу та перетворення файлу логів в датафрейм:

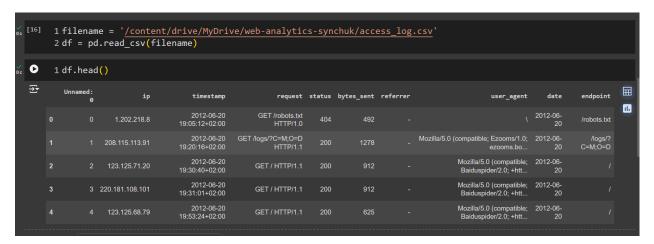
```
def parse_line(line: str) -> dict | None:
    regex = r'(?P<ip>\d+\.\d+\.\d+\.\d+) - - \[(?P<timestamp>.*?)\]
"(?P<request>.*?)" (?P<status>\d+) (?P<bytes_sent>\d+)
"(?P<referrer>.*?)" "(?P<user agent>.*?)"'
    match = re.match(regex, line)
    return match.groupdict() if match else None
def parse_file(filepath: str) -> pd.DataFrame:
    with open(filepath, 'r') as file:
        df rows = []
        for line in file:
            row = parse line(line)
            # print(row)
            if not(row is None):
                df rows.append(row)
    df = pd.DataFrame(df rows)
    # етап обробки датафрейму
    df['timestamp'] = pd.to_datetime(df['timestamp'],
    format='%d/%b/%Y:%H:%M:%S %z', errors='coerce')
    df['status'] = pd.to_numeric(df['status'], errors='coerce')
    df['bytes sent'] = pd.to numeric(df['bytes sent'],
errors='coerce')
    df['date'] = df['timestamp'].dt.date
    df['endpoint'] = df['request'].apply(lambda x: x.split()[1])
    return copy.deepcopy(df)
```

Виконаємо функції

```
# ====== task a
filepath = 'lab-1/access.log'
```

```
df = parse_file(filepath)
df.to_csv('lab-1/access_log.csv')
```

Прочитаємо та переглянемо збережений датафрейм:



а) Визначити кількість користувачів за днями

```
[19]
       1 # кількість користувачів за днями
       2 df.groupby('date')['ip'].nunique()
₹
    date
    2012-06-20
                  21
    2012-06-21
                  69
     2012-06-22
                  68
    2012-06-23
                  83
    2012-06-24
                  78
    2012-06-25
                  73
    2012-06-26
                  90
    2012-06-27
                  73
    2012-06-28
                 ጸጸ
    2012-06-29
                  93
    2012-06-30
                  98
    2012-07-01
                  82
     2012-07-02
                  30
    Name: ip, dtype: int64
```

b) Ранжувати користувачів за User-Agent

```
1 # pahжybatu κορμοτybayib 3a user-agent
2 df.groupby('user_agent')['ip'].nunique().sort_values(ascending=False)

user_agent
Mozilla/5.0 (compatible; Baiduspider/2.0; +http://www.baidu.com/search/spider.html)
Mozilla/5.0 (compatible; MJ12bot/v1.4.3; http://www.majestic12.co.uk/bot.php?+)

Mozilla/5.0 (compatible; AhrefsBot/3.1; +http://ahrefs.com/robot/)
Mozilla/5.0 (Windows NT 5.1; rv:6.0.2) Gecko/20100101 Firefox/6.0.2

Mozilla/5.0 (windows NT 6.1; WOW64) AppleWebKit/535.1 (KHTML, like Gecko) Chrome/14.0.814.0 Safari/535.1

Mozilla/5.0 (Windows NT 6.1) AppleWebKit/536.5 (KHTML, like Gecko) Chrome/19.0.1084.56 Safari/536.5

Mozilla/5.0 (Windows NT 6.1) AppleWebKit/535.19 (KHTML, like Gecko) Chrome/18.0.1025.1 Safari/535.19

Mozilla/5.0 (Windows NT 6.0; rv:12.0) Gecko/20100101 Firefox/12.0

siclab (cboc-test@lab.ntt.co.jp)

Name: ip, Length: 101, dtype: int64
```

с) Ранжувати користувачів за операційними системами

```
# ранжувати користувачів за операційними системами
# ex. : Mozilla/5.0 (Windows NT 5.1; rv:6.0.2)
Gecko/20100101 Firefox/6.0.2
Windows
def extract parentheses content (user agent str:
str) -> str | None:
    pattern = r' \setminus ((.*?) \setminus)'
    match = re.search(pattern, user agent str)
    return match .group(1) if match else None
def identify os(content: str) -> str:
    os patterns = {
        'Windows': r'Windows',
        'Mac OS': r'Macintosh|Mac OS|Mac PowerPC',
        'Linux': r'Linux',
        'Android': r'Android',
        'iOS': r'iPhone|iPad|iPod',
        'Chrome OS': r'CrOS'
    for os, pattern in os patterns.items():
        if re.search(pattern, content,
re. IGNORECASE):
            return os
    return 'Unknown'
def extract os from user agent(user agent str: str)
-> str:
    content =
str(extract parentheses content(user agent str))
    return identify os(content)
```

```
df['os'] =
df['user_agent'].apply(extract_os_from_user_agent)
df.groupby('os')['ip'].nunique()
```

```
os
Linux 10
Mac OS 2
Unknown 329
Windows 119
Name: ip, dtype: int64
```

d) Ранжувати користувачів за країною запиту

```
# Ранжувати користувачів за країною запиту
import geoip2.database
# reader =
geoip2.database.Reader('/content/drive/MyDrive/web-
analytics-synchuk/GeoLite2-City.mmdb')
reader =
geoip2.database.Reader('/content/drive/MyDrive/web-
analytics-synchuk/GeoLite2-Country.mmdb')
# def get country from ip(ip: str) -> str:
      response =
requests.get(f"https://geolocation-
      # print(response)
def get country from ip(ip: str, reader) -> str:
    try:
        response = reader.country(ip)
        return response.country.name
    except Exception:
        return 'Unknown'
df['country'] = df['ip'].apply(lambda ip:
get country from ip(ip, reader))
```

```
0
     1 df.groupby('country')['ip'].nunique().sort values(ascending=False)

→ country

   China
   United States
                     24
   Japan
   Russia
   France
                     14
   Germany
   Ukraine
   The Netherlands
   United Kingdom
   Brazil
   Czechia
   Indonesia
   India
   Israel
   Norway
   Romania
   Sweden
   Ecuador
   Canada
   Thailand
   Malavsia
   Argentina
   Türkiye
   Sri Lanka
```

е) Виокремити пошукових ботів

Детектувати аномалії (якщо такі ϵ)

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

X = df[['hour', 'bytes_sent']]
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
kmeans = KMeans(n_clusters=4)
df['cluster'] = kmeans.fit_predict(X_scaled)

plt.figure(figsize=(10, 6))
```

```
for cluster_label in df['cluster'].unique():
        cluster_data = df[df['cluster'] ==
        cluster_label]

        plt.scatter(cluster_data['hour'],
        cluster_data['bytes_sent'],
        label=f'Cluster {cluster_label}')

plt.xlabel('Hour of the Day')
plt.ylabel('Bytes Sent')
plt.title('Clusters of Data')
plt.legend()
plt.grid(True)
plt.show()
```

